



Stars 66k

Forks 5.5k

open issues 16

closed issues 2.2k

pypi v3.2.1

python 3.10 | 3.11 | 3.12 | 3.13

downloads 2M

downloads/month 282k

webapp on mineru.net

Demo on ModelScope

Demo on HuggingFace

Open in Colab

MinerU Technical Report

MinerU2.5 Technical Report

MinerU2.5 Pro Technical Report

Ask DeepWiki

1

GITHUB TRENDING

#1 Repository Of The Day

[English](#) | [简体中文](#)

[MinerU 官网入口](#)→ 免装在线版 全功能客户端 开发者API在线调用，省去部署麻烦，多种产品形态一键get，速冲！

join us on [Discord](#) and [WeChat](#)

► MinerU — 专为 LLM · RAG · Agent 场景构建的高精度文档解析引擎

核心解析能力

- 原生支持 DOCX、PPTX、XLSX 解析
- 公式 → LaTeX · 表格 → HTML，精准还原复杂版面
- 支持扫描件、手写体、多栏布局、跨页表格合并
- 输出符合人类阅读顺序，自动去除页眉页脚
- VLM + OCR 双引擎，支持 109 种语言识别

接入方式

场景	方案
AI 编程工具	MCP Server — Cursor · Claude Desktop · Windsurf

场景	方案
RAG 框架	LangChain · LlamaIndex · RAGFlow · RAG-Anything · Flowise · Dify · FastGPT
开发集成	Python / Go / TypeScript SDK · CLI · REST API · Docker
零代码	mineru.net 在线版 · Gradio WebUI · 桌面客户端

部署生态（支持私有化 · 完全离线）

推理后端	适用场景
pipeline	快速稳定，无幻觉，CPU / GPU 均可运行
vlm-engine	高精度，支持 vLLM / LMdeploy / mlx 生态
hybrid-engine	高精度，原生文本提取，低幻觉

国产算力：昇腾 · 寒武纪 · 燧原 · 沐曦 · 摩尔线程 · 昆仑芯 · 天数智芯 · 瀚博 · 太初元基 · 海光 · 平头哥

更新记录

- 2026/04/18 3.1.0 发布

本次版本更新聚焦于**许可协议开放性、解析精度提升与全格式原生支持**。主要更新内容包括：

- 许可协议升级
 - MinerU 已正式从 AGPLv3 切换至基于 Apache 2.0 的 [MinerU 开源许可证](#)。
 - 新的许可方式在兼顾开源协作与商业落地的同时，进一步降低了社区使用和商业接入门槛，让 MinerU 更容易融入真实业务流程。
- VLM 主模型升级
 - VLM 主模型正式切换为 `MinerU2.5-Pro-2604-1.2B`，整体解析精度提升至业内领先水平。
 - 新模型现已支持子图切分合并、图像与图表解析、截断段落合并、跨页面表格合并以及表格内图像识别，复杂版面场景下的解析能力进一步增强。
- 全格式原生解析支持
 - 新增 `PPTX` 与 `XLSX` 原生解析能力。
 - 至此，MinerU 已完整支持图片、`PDF`、`DOCX`、`PPTX`、`XLSX` 全格式解析，为多类型文档统一处理提供了更完整的能力闭环。

通过 3.1.0 版本，MinerU 在开放性、解析精度和落地能力上进一步提升。新的许可协议降低了社区使用和商业接入门槛，`MinerU2.5-Pro-2604-1.2B` 提升了复杂内容的解析质量，而 `PPTX` 与 `XLSX` 原生解析的补齐，也让 MinerU 完成了主流文档格式的端到端覆盖。

- 2026/03/29 3.0.0 发布

本次版本更新围绕**解析能力、系统架构与工程可用性**进行了系统升级。主要更新内容包括：

- `DOCX` 原生解析
 - 正式支持 `DOCX` 原生解析，在无幻觉前提下实现高精度解析。
 - 相较于“先将 `DOCX` 转为 `PDF` 再解析”的传统流程，端到端速度提升数十倍以上，更适合对精度与吞吐均有要求的场景。
- `pipeline` 后端升级

- `pipeline` 后端在 OmniDocBench (v1.5) 上取得 86.2 分，精度超过上一代主流 VLM MinerU2.0-2505-0.9B。
- 新增表格内图片/公式解析、印章文字识别、竖排文本支持、行间公式序号识别等能力，持续提升复杂文档场景下的解析效果。
- 在保持高精度的同时，资源占用极低，并继续支持纯 CPU 环境推理。
- API / CLI / Router 编排升级
 - `mineru` 现作为基于 `mineru-api` 的编排客户端运行；在未传入 `--api-url` 时，会自动拉起本地临时服务。
 - `mineru-api` 新增异步任务接口 `POST /tasks`，支持任务提交、状态查询与结果获取；同时保留同步解析接口 `POST /file_parse`，以兼容老版本插件。
 - 新增 `mineru-router`，适用于多服务、多 GPU 的统一入口部署与任务路由；其接口与 `mineru-api` 完全兼容，并支持任务自动负载均衡。
- 部署与使用体验优化
 - 解决了 `torch >= 2.8` 的兼容问题，基础镜像升级为 `vllm0.11.2 + torch2.9.0`，统一了不同 Compute Capability 的安装路径。
 - 通过滑动窗口优化解析链路，显著降低长文档场景下的内存峰值占用，上万页文档解析不再需要手动拆分。
 - `pipeline` 的 batch 推理支持流式落盘，已完成的解析结果可及时写出，进一步提升长任务处理体验。
 - 完成线程安全优化，全面支持多线程并发推理；配合 `mineru-router`，可一键实现多卡部署，轻松构建高并发、高吞吐解析系统。
 - 完全移除了两个 AGPLv3 模型（`doclayoutyolo` 和 `mfd_yolov8`）以及一个 CC-BY-NC-SA 4.0 模型（`layoutreader`）的使用。

本次更新不仅是若干功能点的补强，更是 MinerU 在系统能力上的一次关键跃迁。我们重点解决了长文档解析过程中的内存峰值占用问题，通过滑动窗口、流式落盘等链路优化，让超长文档解析从“需要手动拆分、谨慎处理”走向“稳定可跑、规模可扩展”。同时，我们完成了线程安全优化，全面支持多线程并发推理，进一步提升了单机资源利用率与高并发场景下的运行稳定性。在此基础上，基于 `mineru-router` 与全新的 API / CLI 编排体系，MinerU 已具备一键多卡部署、多服务统一接入、任务自动负载均衡的能力，显著降低了大规模部署难度。至此，MinerU 正在从单一的数据生产工具，进一步演进为面向高并发、高吞吐场景的大规模文档解析基座，为企业级文档数据处理提供更稳定、更高效、更易扩展的基础设施能力。

 查看完整的 [更新日志](#) 了解更多历史版本信息

MinerU

项目简介

MinerU 是一款文档解析工具，可将 PDF、图片以及 DOCX、PPTX、XLSX 转化为机器可读格式（如 Markdown、JSON），便于后续检索、抽取与二次处理。

MinerU 诞生于 [书生·浦语](#) 的预训练过程中，我们将会集中精力解决科技文献中的符号转化问题，希望在大模型时代为科技发展做出贡献。

相比国内外知名商用产品 MinerU 还很年轻，如果遇到问题或者结果不及预期请到 [issue](#) 提交问题，同时附上相关文档或样例文件。

<https://github.com/user-attachments/assets/4bea02c9-6d54-4cd6-97ed-dff14340982c>

主要功能

- 支持 PDF、图片与 DOCX、PPTX、XLSX 输入
- 删除页眉、页脚、脚注、页码等元素，确保语义连贯
- 输出符合人类阅读顺序的文本，适用于单栏、多栏及复杂排版
- 保留原文档的结构，包括标题、段落、列表等
- 提取图像、图片描述、表格、表格标题及脚注
- 自动识别并转换文档中的公式为LaTeX格式
- 自动识别并转换文档中的表格为HTML格式
- 自动检测扫描版PDF和乱码PDF，并启用OCR功能
- OCR支持109种语言的检测与识别
- 支持多种输出格式，如多模态与NLP的Markdown、按阅读顺序排序的JSON、含有丰富信息的中间格式等
- 支持多种可视化结果，包括layout可视化、span可视化等，便于高效确认输出效果与质检
- 内置命令行、FastAPI、Gradio WebUI，支持本地编排和多服务部署
- 支持纯CPU环境运行，并支持 GPU/MPS加速，以及十余款国产算力平台的推理加速
- 兼容Windows、Linux和Mac平台

快速开始

文档解析是困难且复杂的任务，尤其是对于复杂版面、扫描件、手写体等场景，解析结果可能不尽如人意。我们建议您先使用在线体验评估 MinerU 的解析效果和适用性，再根据实际需求选择合适的部署方式。

如果您有解析效果不佳的文档样例，欢迎提交上传到 [issue](#)，我们会持续优化解析能力。

如果安装或使用中遇到任何问题，请先查询 [FAQ](#)。

在线体验

官网在线应用

官网在线版功能与客户端一致，界面美观，功能丰富，需要登录使用

-  [webapp on mineru.net](#)

基于Gradio的在线demo

基于gradio开发的webui，界面简洁，仅包含核心解析功能，免登录

-  [Demo on ModelScope](#)
-  [Demo on HuggingFace](#)

本地部署

⚠ Warning

安装前必看——软硬件环境支持说明

为了确保项目的稳定性和可靠性，我们在开发过程中仅对特定的软硬件环境进行优化和测试。这样当用户在推荐的系统配置上部署和运行项目时，能够获得最佳的性能表现和最少的兼容性问题。

通过集中资源和精力于主线环境，我们团队能够更高效地解决潜在的BUG，及时开发新功能。

在非主线环境中，由于硬件、软件配置的多样性，以及第三方依赖项的兼容性问题，我们无法100%保证项目的完全可用性。因此，对于希望在非推荐环境中使用本项目的用户，我们建议先仔细阅读文档以及FAQ，大多数问题已经在FAQ中有对应的解决方案，除此之外我们鼓励社区反馈问题，以便我们能够逐步扩大支持范围。

解析后端	pipeline	*-auto-engine		*-http-client	
		hybrid	vlm	hybrid	vlm
后端特性	兼容性好	硬件配置要求较高		适用于OpenAI兼容服务器 ²	
精度指标 ¹	85+	95+			
操作系统	Linux ³ / Windows ⁴ / macOS ⁵				
纯CPU平台支持	✓	✗		✓	
GPU加速支持	Volta及以后架构GPU或Apple Silicon				不需要
显存最低要求	4GB	8GB	8GB	2GB	
内存要求	最低16GB以上,推荐32GB以上			最低16GB	
磁盘空间要求	20GB以上,推荐使用SSD			至少2GB	
python版本	3.10-3.13				

¹ 精度指标为OmniDocBench (v1.6)的End-to-End Evaluation Overall分数，基于 MinerU 最新版本测试

² 兼容OpenAI API的服务器，如通过 vLLM / SGLang / LMDeploy 等推理框架部署的本地模型服务器或远程模型服务

³ Linux仅支持2019年及以后发行版

⁴ 由于关键依赖 ray 未能在windows平台支持Python 3.13，故仅支持至3.10~3.12版本

⁵ macOS 需使用14.0以上版本

💡 Tip

- 除以上主流环境与平台外，我们也收录了一些社区用户反馈的其他平台支持情况，详情请参考[其他加速卡适配](#)。
- 如果您有意将自己的环境适配经验分享给社区，欢迎通过[show-and-tell](#)提交或提交PR至[其他加速卡适配](#)文档。

安装 MinerU

使用pip或uv安装MinerU

```
1 pip install --upgrade pip -i https://mirrors.aliyun.com/pypi/simple
2 pip install uv -i https://mirrors.aliyun.com/pypi/simple
3 uv pip install -U "mineru[all]" -i https://mirrors.aliyun.com/pypi/simple
```

通过源码安装MinerU

```
1 git clone https://github.com/opendatalab/MinerU.git
2 cd MinerU
3 uv pip install -e .[all] -i https://mirrors.aliyun.com/pypi/simple
```

💡 Tip

- `mineru[all]` 包含所有核心功能，兼容Windows / Linux / macOS系统，适合绝大多数用户。
- 如果您在 Windows 上安装后无法使用 CUDA 加速，请参考 [Windows CUDA 加速 FAQ](#)。
- 如果您需要指定vlm模型的推理框架，或是仅准备在边缘设备安装轻量版client端，可以参考文档[扩展模块安装指南](#)。

使用docker部署Mineru

MinerU提供了便捷的docker部署方式，这有助于快速搭建环境并解决一些棘手的环境兼容问题。

💡 Tip

- Docker 部署仅适用于 Linux，以及支持 WSL2 的 Windows 环境；
- macOS 用户请直接参考前面两种方式部署安装，不要使用 Docker 部署。

您可以在文档中获取[Docker部署说明](#)。

使用 MinerU

💡 Tip

默认使用托管在 huggingface 的模型进行解析，首次使用时会自动下载所需模型文件，后续使用将直接加载本地缓存的模型。如果您无法访问 huggingface，可以通过以下命令切换至国内镜像源：

```
1 | export MINERU_MODEL_SOURCE=modelscope
```

如果您的设备满足上表中GPU加速的条件，可以使用简单的命令行进行文档解析：

```
1 | mineru -p <input_path> -o <output_path>
```

如果您的设备不满足GPU加速条件，可以指定后端为 `pipeline`，以在纯CPU环境下运行：

```
1 | mineru -p <input_path> -o <output_path> -b pipeline
```

当前 `mineru` 支持本地 PDF / 图片 / DOCX / PPTX / XLSX 文件或目录输入，并可通过命令行、API、WebUI、`mineru-router` 等多种方式进行文档解析，具体使用方法请参考[使用指南](#)。

FAQ

- 如果您在使用过程中遇到问题，可以先查看[常见问题](#)是否有解答。
- 如果未能解决您的问题，您也可以使用[DeepWiki](#)与AI助手交流，这可以解决大部分常见问题。
- 如果您仍然无法解决问题，您可通过[Discord](#)或[WeChat](#)加入社区，与其他用户和开发者交流。

All Thanks To Our Contributors



License Information

本仓库采用 [MinerU 开源许可证](#) 进行许可，基于 Apache 2.0 并附带额外条款。

Acknowledgments

- [UniMERNet](#)
- [TableStructureRec](#)
- [PaddleOCR](#)
- [PaddleOCR2Pytorch](#)
- [fast-langdetect](#)
- [pypdfium2](#)
- [pdftext](#)
- [pypdf](#)
- [magika](#)
- [vLLM](#)
- [LMDeploy](#)


Citation

```
1 @article{wang2026mineru2,  
2   title={MinerU2. 5-Pro: Pushing the Limits of Data-Centric Document Parsing at  
   Scale},  
3   author={Wang, Bin and He, Tianyao and Ouyang, Linke and Wu, Fan and Zhao, Zhiyuan  
   and Chu, Tao and Qu, Yuan and Jin, Zhenjiang and Zeng, Weijun and Miao, Ziyang and  
   others},
```

```
4   journal={arxiv preprint arxiv:2604.04771},
5   year={2026}
6 }
7
8 @article{dong2026minerudiffusion,
9   title={MinerU-Diffusion: Rethinking Document OCR as Inverse Rendering via Diffusion
10  Decoding},
11   author={Dong, Hejun and Niu, Junbo and Wang, Bin and Zeng, Weijun and Zhang, Wentao
12  and He, Conghui},
13   journal={arxiv preprint arxiv:2603.22458},
14   year={2026}
15 }
16
17 @article{niu2025mineru2,
18   title={Mineru2. 5: A decoupled vision-language model for efficient high-resolution
19  document parsing},
20   author={Niu, Junbo and Liu, Zheng and Gu, Zhuangcheng and Wang, Bin and Ouyang,
21  Linke and Zhao, Zhiyuan and Chu, Tao and He, Tianyao and Wu, Fan and Zhang, Qintong
22  and others},
23   journal={arxiv preprint arxiv:2509.22186},
24   year={2025}
25 }
26
27 @article{wang2024mineru,
28   title={Mineru: An open-source solution for precise document content extraction},
29   author={Wang, Bin and Xu, Chao and Zhao, Xiaomeng and Ouyang, Linke and Wu, Fan and
30  Zhao, Zhiyuan and Xu, Rui and Liu, Kaiwen and Qu, Yuan and Shang, Fukai and others},
31   journal={arxiv preprint arxiv:2409.18839},
32   year={2024}
33 }
34
35 @article{he2024opendatalab,
36   title={Opendatalab: Empowering general artificial intelligence with open datasets},
37   author={He, Conghui and Li, Wei and Jin, Zhenjiang and Xu, Chao and Wang, Bin and
38  Lin, Dahua},
39   journal={arxiv preprint arxiv:2407.13773},
40   year={2024}
41 }
```

Star History

Star History



Links

- [Easy Data Preparation with latest LLMs-based Operators and Pipelines](#)
- [Vis3 \(OSS browser based on s3\)](#)
- [LabelU \(A Lightweight Multi-modal Data Annotation Tool\)](#)
- [LabelLLM \(An Open-source LLM Dialogue Annotation Platform\)](#)
- [PDF-Extract-Kit \(A Comprehensive Toolkit for High-Quality PDF Content Extraction\)](#)
- [OmniDocBench \(A Comprehensive Benchmark for Document Parsing and Evaluation\)](#)
- [Magic-HTML \(Mixed web page extraction tool\)](#)
- [Magic-Doc \(Fast speed ppt/pptx/doc/docx/pdf extraction tool\)](#)
- [Dingo: A Comprehensive AI Data Quality Evaluation Tool](#)